

Johnson-Lindenstrauss lema

Kratek opis

Klara Doler in Eva Winkler

17. 12. 2021

1 Definicije in leme


Johnson-Lindenstraussova lema

Naj bo $0 < \varepsilon < 1$ in $n \in \mathbb{N}$. Predpostavimo, da je $k > \frac{8 \log(n)}{\varepsilon^2}$. Potem za vsak nabor m točk iz množice $X \subset \mathbb{R}^d$ obstaja taka preslikava $f : \mathbb{R}^d \rightarrow \mathbb{R}^k$, da za vse $u, v \in X$ velja:

$$(1 - \varepsilon)\|u - v\|^2 \leq \|f(u) - f(v)\|^2 \leq (1 + \varepsilon)\|u - v\|^2$$

Zgornje lahko zapišemo tudi kot:

$$(1 + \varepsilon)^{-1}\|f(u) - f(v)\|^2 \leq \|u - v\|^2 \leq (1 + \varepsilon)\|f(u) - f(v)\|^2$$



Slika 1: Slika prikazuje preslikavo točk s $f : \mathbb{R}^N \rightarrow \mathbb{R}^M$, za $N > M$

Johnson-Lindenstraussova distribucija

Sorodna lema je distribucijska Johnson-Lindenstraussova lema. Ta lema pravi, da za katerakoli $0 < \varepsilon, \delta < \frac{1}{2}$ in pozitivno celo število d , obstaja porazdelitev na $\mathbb{R}^{k \times d}$, iz katere je sestavljena matrika A , tako da za $k = O(\varepsilon^{-2} \log(\frac{1}{\delta}))$ in za kateri koli enotski vektor $x \in \mathbb{R}^d$ velja spodnja trditev:

$$P(|\|Ax\|_2^2 - 1| > \varepsilon) < \delta$$

Vidimo lahko, da lahko lemo JL pridobimo iz distribucijske različe tako, da nastavimo $x = \frac{u-v}{\|u-v\|^2}$ in $\delta < \frac{1}{n^2}$ za nek par $u, v \in X$.

Definicija 1.1 Končno razsežen vektorski prostor nad \mathbb{R} opremljen s skalarnim produktom imenujemo evklidski prostor.

Definicija 1.2 V n -razsežnem evklidskem prostoru \mathbb{R}^n je dolžina vektorja $\vec{x} = [x_1, x_2, \dots, x_n]$ določena z

$$\|\vec{x}\| = \sqrt{(x_1)^2 + (x_2)^2 + (x_3)^2 + \dots + (x_n)^2}.$$

Imenujemo jo evklidska norma.

2 Opis problema in navodilo

V projektni nalogi se bova ukvarjali z Johnson-Lindenstraussovo lemo, poimenovano po Williamu B. Johnsonu in Joramu Lindenstraussu. Lema pravi, da je mogoče množico točk iz visokodimenzionalnega prostora projicirati v podprostor dimenzije $O(\frac{\log(n)}{\epsilon^2})$ tako, da se razdalja med poljubnima točkama z veliko verjetnostjo spremeni za največ ϵ . V najini nalogi bova preverili veljavnost leme.

3 Opis dela

Za izvedbo najinega problema bova uporabili programski jezik *Python*. Programirali bova v *Cocalc* – *u*, ki ima vgrajene funkcije za delo z matrikami. Izvedli bova poskuse, s katerimi bova preverili, ali distribucijska JL lema drži:

- izbrali bova vzorec točk v prostoru določene dimenzije, ki je odvisen od ϵ ,
- naredili bova projekcijo izbranih točk na podprostor,
- primerjale bova razdaljo med točkami v podprostoru z originalno razdaljo,
- za konec bova še pogledali, kakšna je verjetnost, da je razdalja med točkami spremenjena za največ ϵ (ter npr. $\frac{\epsilon}{2}$).